

```
In [123]: import numpy as np
import matplotlib.pyplot as plt
import scipy.stats as sps
import math
%matplotlib inline
smp_cov = 1
smp_mean = 0
```

[https://en.wikipedia.org/wiki/Conjugate\\_prior](https://en.wikipedia.org/wiki/Conjugate_prior) ([https://en.wikipedia.org/wiki/Conjugate\\_prior](https://en.wikipedia.org/wiki/Conjugate_prior))

```
In [124]: sample = sps.norm.rvs(size=100, loc=smp_mean, scale=smp_cov)
```

```
In [125]: #get argmax of likelyhood function for N(\theta , 1)
n = np.arange(1,101,1)
likelyhood_mean_evl = [abs(sample[0:k+1].mean()) for k in n]
```

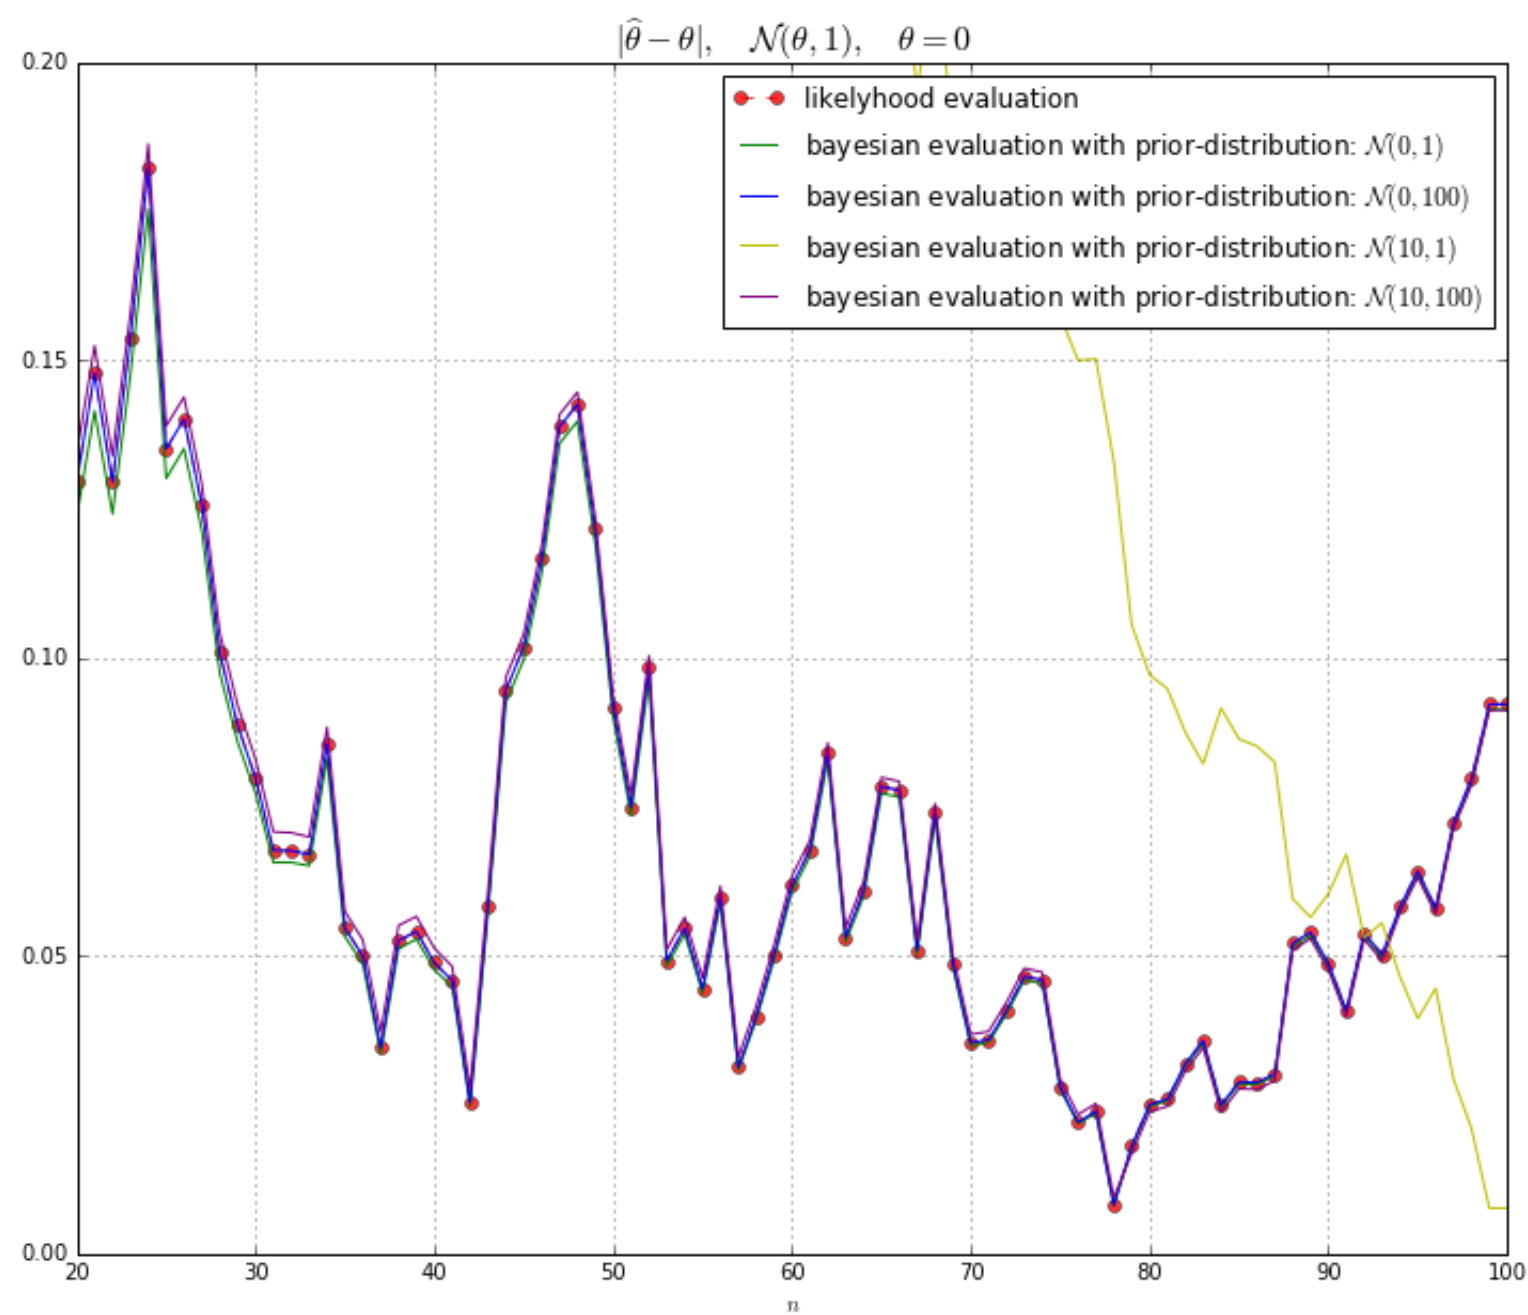
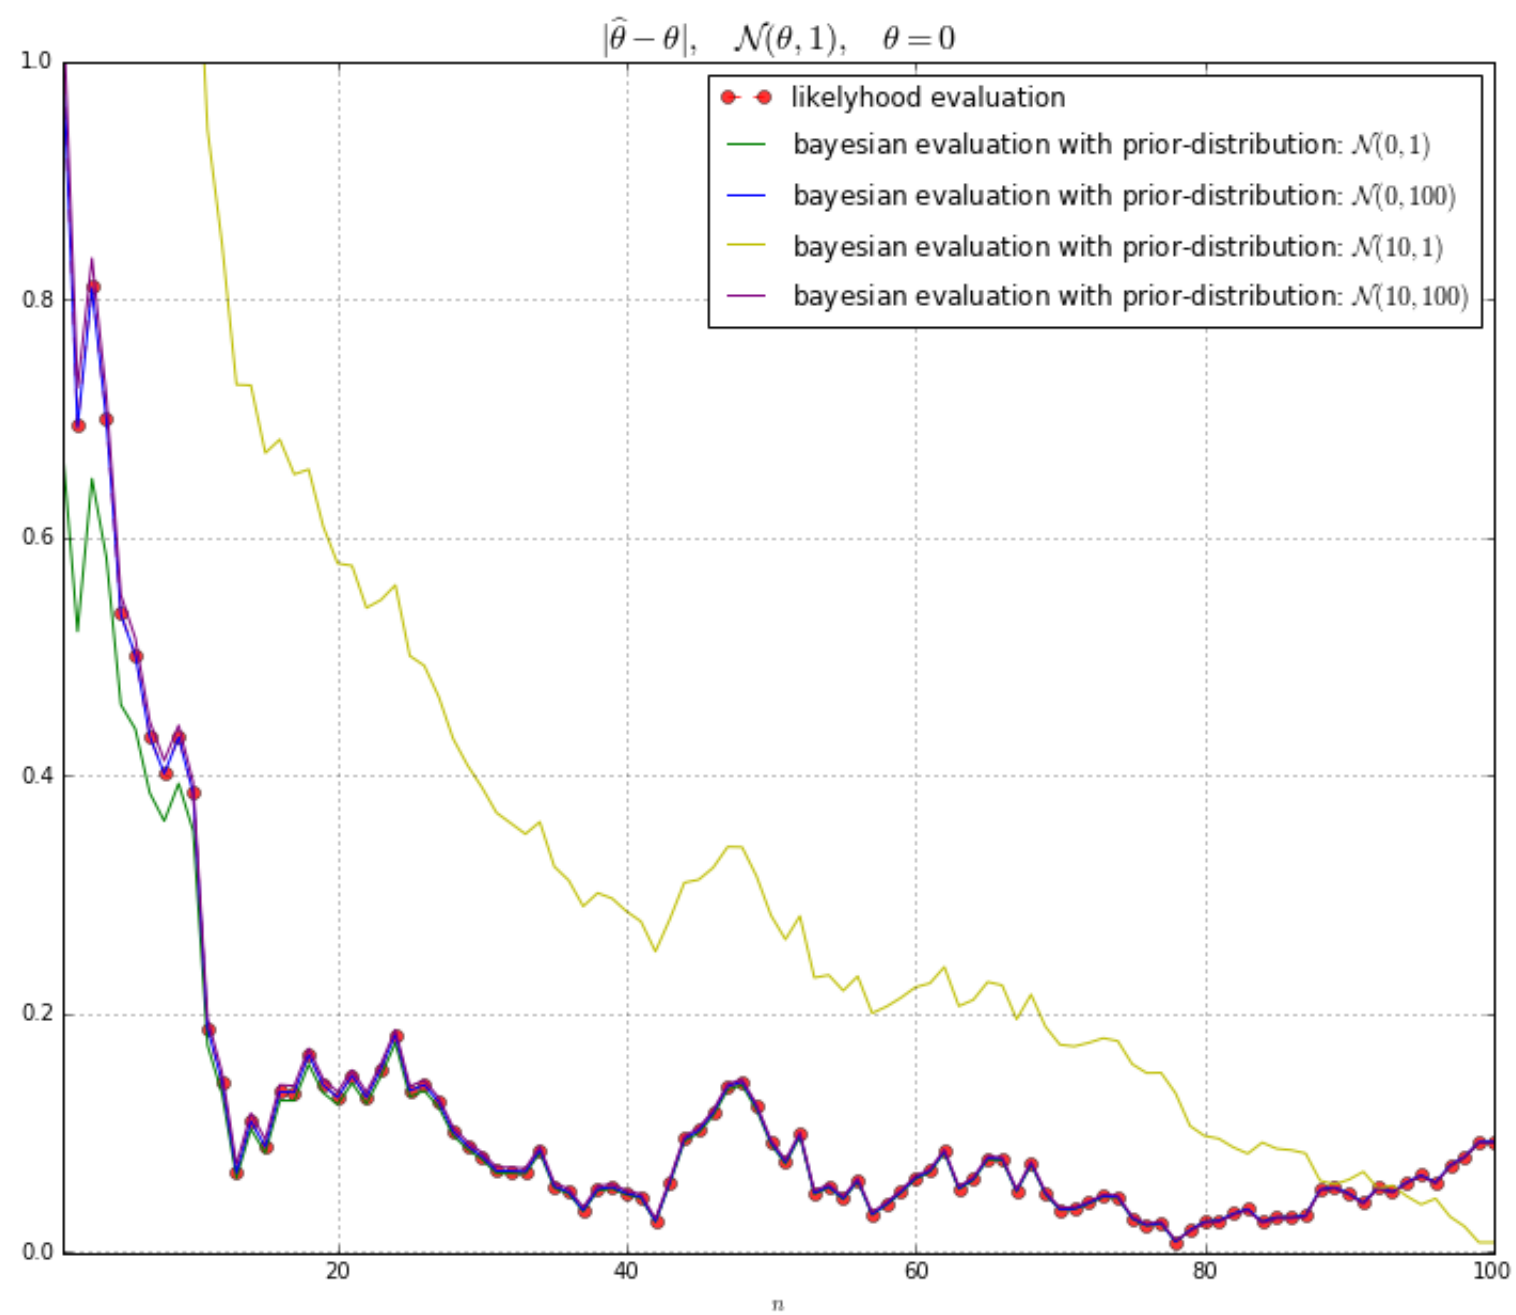
```
In [113]: def get_bayesian_mean_evaluation(X, prior_params) :
pr_mean,pr_cov = prior_params
return (pr_mean/pr_cov + np.sum(X)/smp_cov)/(1/pr_cov + len(X)/smp_cov)
```

```
In [126]: #calc bayesian mean evaluations for all sets of params
prior_mean_params = [(0, 1), (0, 100), (10, 1), (10, 100)]
bayesian_mean_evl = [[abs(get_bayesian_mean_evaluation(
sample[0:k+1],prior_mean_params[i]))
for k in n]
for i in range(4)]
```

```
In [128]: colors = ['--or' , 'g' , 'b' , 'y', 'purple']
title = r'$|\widehat{\theta} - \theta|, $\'
+r'$\quad \mathcal{N}(\theta,1), $\'
+r'$\quad \theta = 0$'
#build plot with absolute evaluation's deviations
def build_plot(axis_params):
plt.figure(figsize=(12,10))
plt.title(title, fontsize=16)
plt.xlabel(r'$n$')
plt.axis(axis_params)
plt.grid(True)
plt.plot(n,likelyhood_mean_evl,colors[0],
label = 'likelyhood evaluation',
alpha=0.8)
for i in range(4):
plt.plot(n, bayesian_mean_evl[i],colors[i+1],
label = 'bayesian evaluation with prior-distribution: '
+ r'$\mathcal{N}('
+ str(prior_mean_params[i][0]) + ', '
+ str(prior_mean_params[i][1]) + r')$')

plt.legend()
plt.show()

build_plot([1,100 , -0.001 , 1])
build_plot([20,100 , 0 , 0.2])
```



Баесовская оценка мат.ожидания нормального распределения асимптотически равна оценке максимального правдоподобия, что и видно на графиках. Также, важна точность подбора априорного распределения. Для  $\mathcal{N}(10, 1)$  ожидаемое значение  $\theta$  отличается на 10 от реального, и имеет малую дисперсию, поэтому график этой оценки отличается сильнее и дает более слабое приближение. В случае  $\mathcal{N}(10, 100)$  этого не происходит, так как велико значение дисперсии.

In [173]:

```
def scale_in_mean(params) :
    nu,tau2 = params
    if nu > 2 :
        return (nu * tau2)/(nu - 2)
    return -np.inf

def get_cov(X,mean):
    return np.sum([(x - mean) ** 2 for x in X])

def get_bayesian_cov_evaluation(X, prior_params):
    prior_mean, prior_cov = prior_params
    nu = len(X) + prior_mean
    tau2 = (prior_mean * prior_cov + get_cov(X,smp_mean))/(prior_mean + len(X))
    return scale_in_mean((nu,tau2))
```

In [174]:

```
#get argmax of likelyhood function for N(1 , \sigma^2)
n = np.arange(1,101,1)
likelyhood_cov_evl = [abs(1 - np.power(sample[0:k+1],2).mean()) for k in n]
```

In [175]:

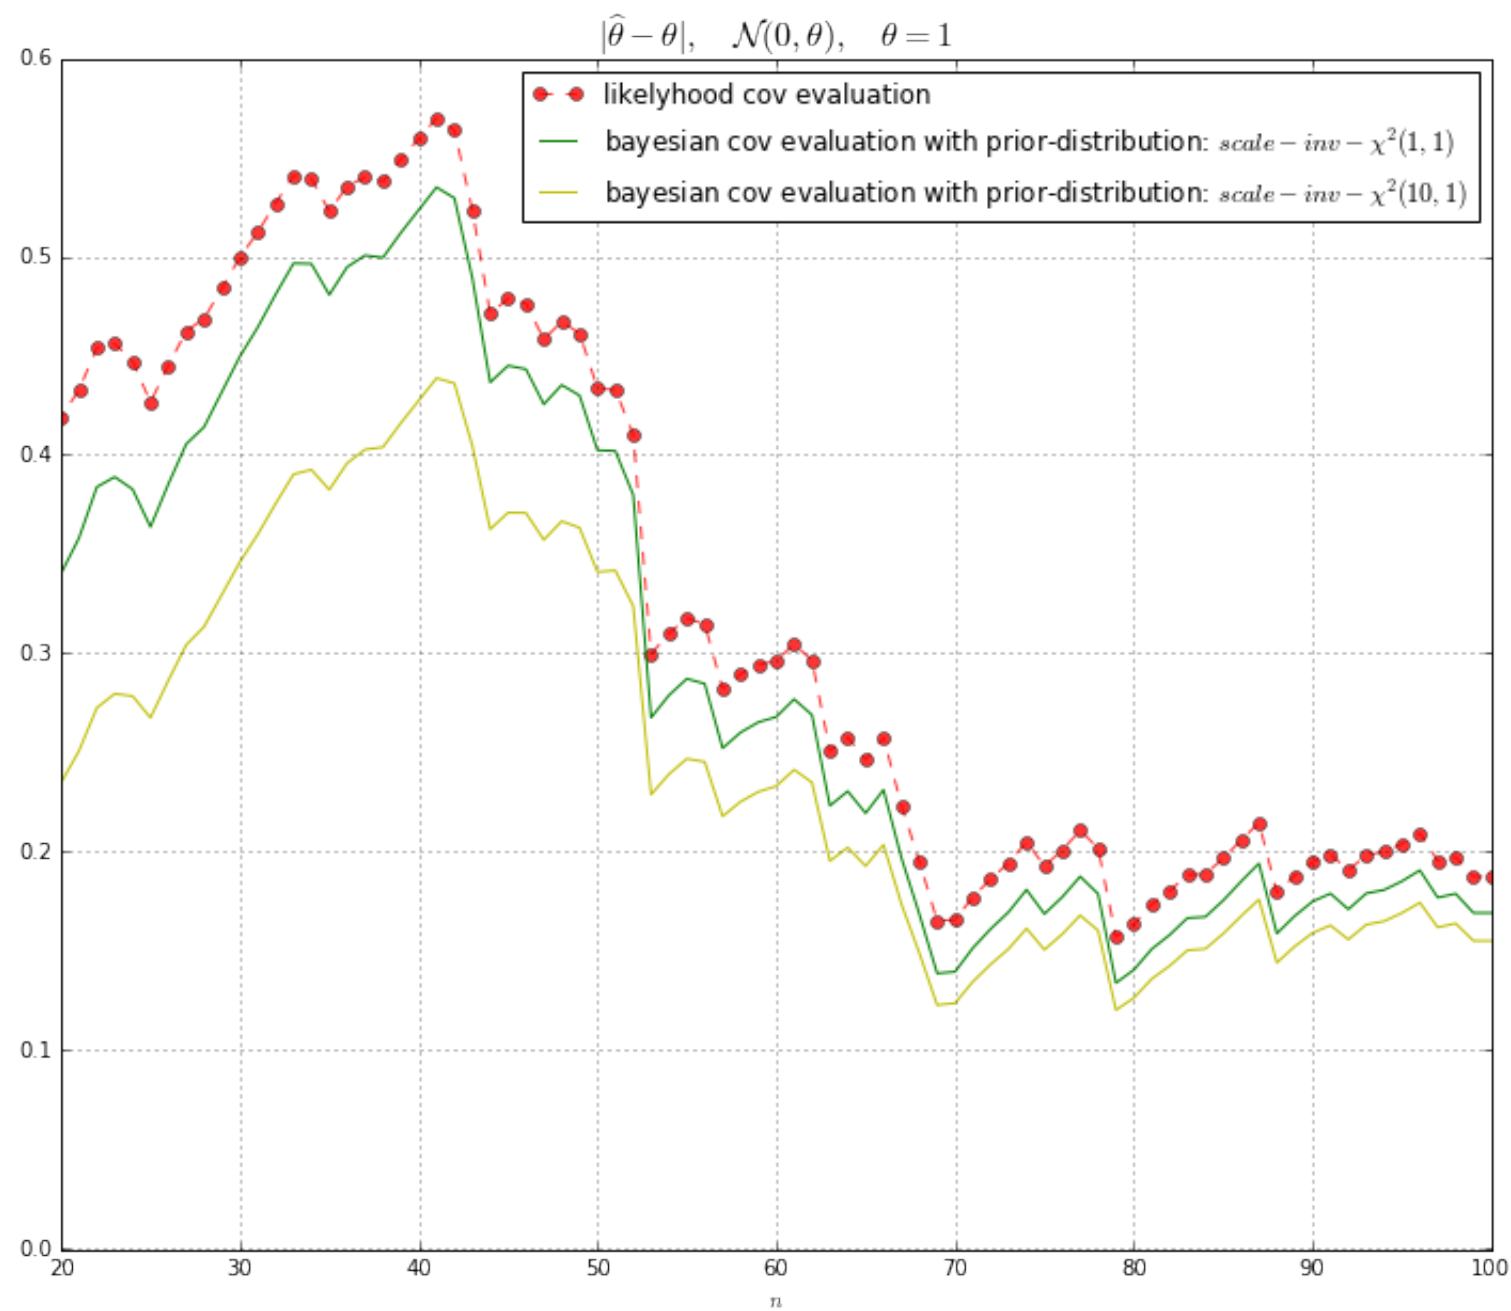
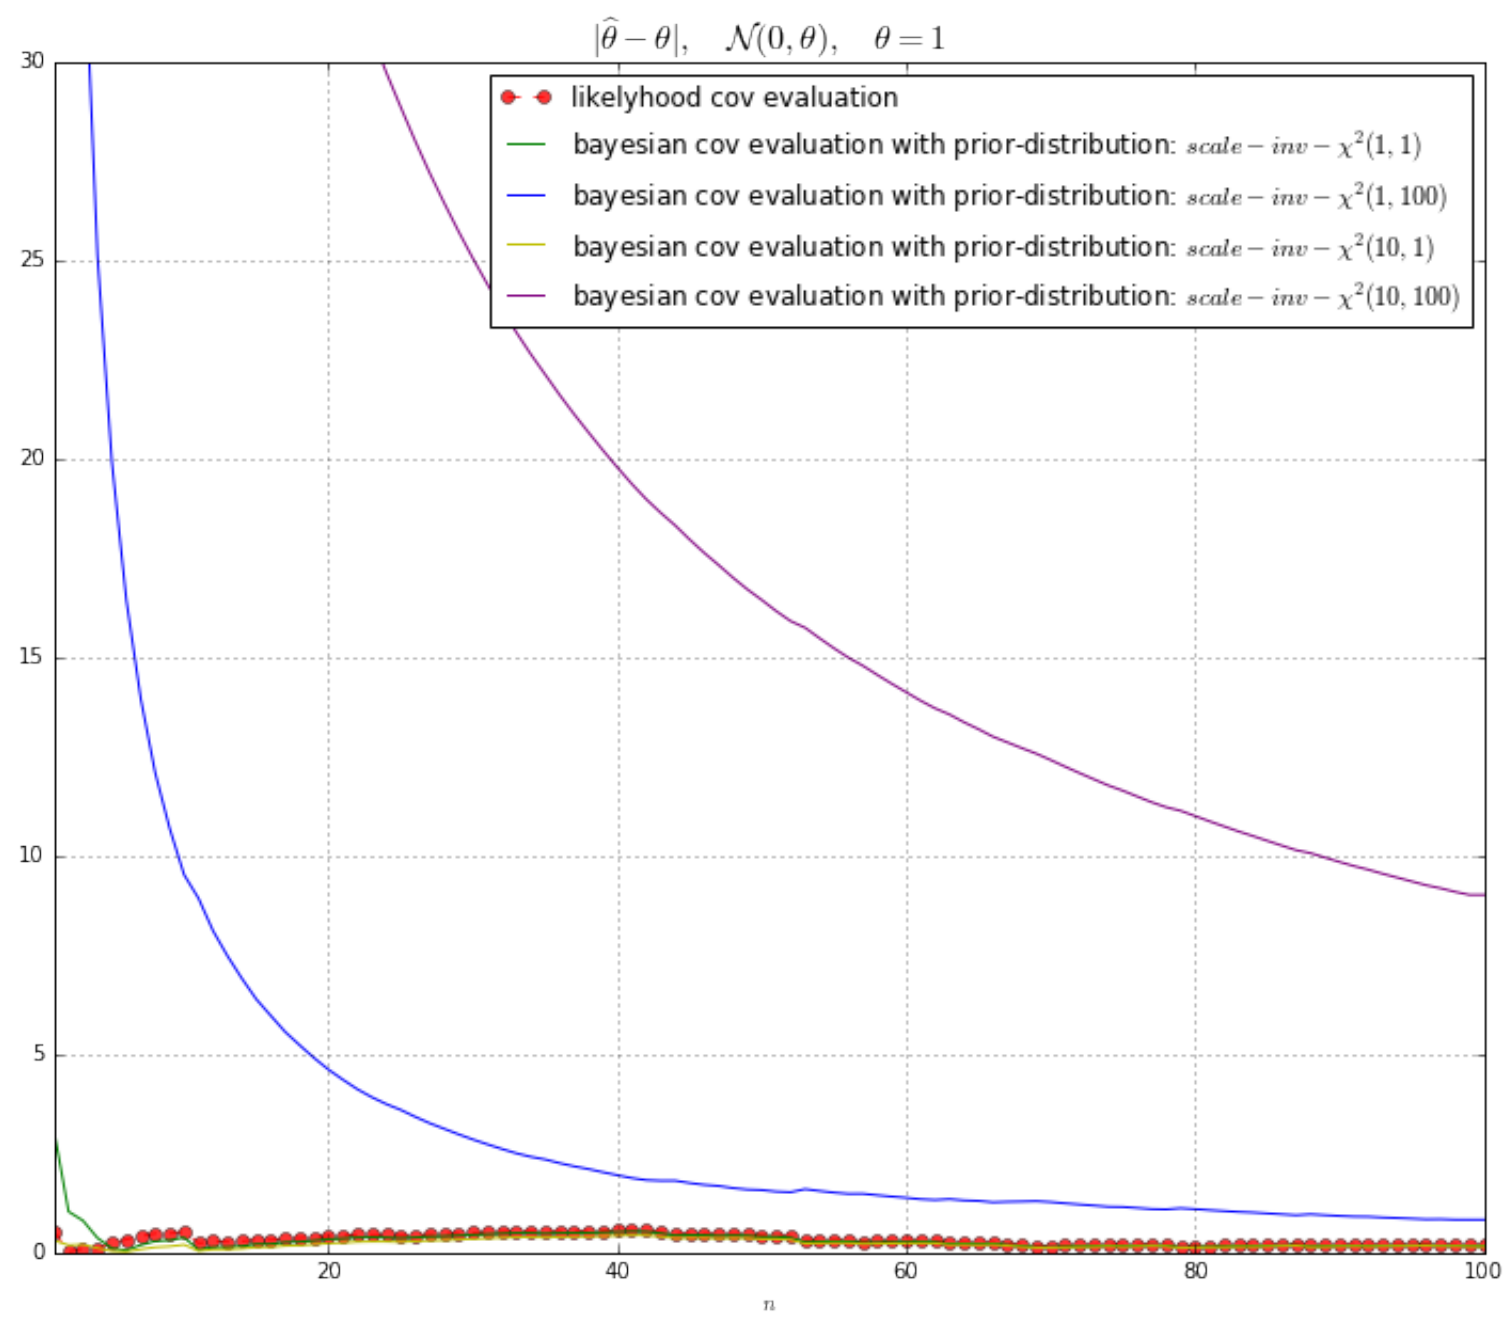
```
#calc bayesian covariation - evaluations for all sets of params
prior_cov_params = [(1, 1), (1, 100), (10, 1), (10, 100)]
bayesian_cov_evl = [[abs(1-get_bayesian_cov_evaluation(
    sample[0:k+1],prior_cov_params[i]))
    for k in n]
    for i in range(4)]
```

In [176]:

```
colors = ['--or' , 'g' , 'b' , 'y', 'purple']
title = r'$|\widehat{\theta} - \theta|, $\'
    +r'$\quad \mathcal{N}(0,\theta), $\'
    +r'$\quad \theta = 1$'
#build plot with absolute evaluation's deviations
def build_plot(axis_params,exclude={}):
    plt.figure(figsize=(12,10))
    plt.title(title, fontsize=16)
    plt.xlabel(r'$n$')
    plt.axis(axis_params)
    plt.grid(True)
    plt.plot(n,likelyhood_cov_evl,colors[0],
        label = 'likelyhood cov evaluation',
        alpha=0.8)
    for i in range(4):
        #skip some evaluations
        if i in exclude:
            continue;
        plt.plot(n, bayesian_cov_evl[i],colors[i+1],
            label = 'bayesian cov evaluation with prior-distribution: '
                + r'$scale-inv-\chi^2('
                + str(prior_cov_params[i][0]) + ','
                + str(prior_cov_params[i][1]) + r')$')

    plt.legend()
    plt.show()

build_plot([1,100 , -0.001 , 30])
build_plot([20,100 , -0.001 , 0.6],[1,3])
```



```
In [177]: def scale_in_mode(params) :
          nu , tau2 = params
          return (nu*tau2)/(nu+2)
```

```
In [199]: sci_mode = [scale_in_mode(params) for params in prior_cov_params]
sci_mean = [scale_in_mean(params) for params in prior_cov_params]
for i in range(len(prior_cov_params)) :
    print('sci(' + str(prior_cov_params[i][0]) + ', '
          + str(prior_cov_params[i][1]) + ') '
          + "mean: " + str(sci_mean[i]) + " , mode: " + str(round(sci_mode[i],3)))
```

```
sci(1,1) mean: -inf , mode: 0.333
sci(1,100) mean: -inf , mode: 33.333
sci(10,1) mean: 1.25 , mode: 0.833
sci(10,100) mean: 125.0 , mode: 83.333
```

При правильном подборе априорного распределения байесовские оценки довольно точны, и сравнимы с оценкой максимального правдоподобия.

В задаче  $\theta = 1$ ,  $sci(1, 1)$  и  $sci(10, 1)$  дают более точное предположение об истинном значении параметра.

$$Mode_{sci(1,1)}\theta \approx 0.33 \text{ (мат ожидания нет)}$$

$$E_{sci(10,1)}\theta = 1.25$$

$sci(1, 100)$  и  $sci(10, 100)$  оценивают параметр значительно хуже.

$$Mode_{sci(1,100)}\theta \approx 33.33 \text{ (мат ожидания нет)}$$

$$E_{sci(10,100)}\theta = 125.0$$